

¿Portabilidad o Competencia? Política de datos en la era FinTech

J. R. Arenas^{1*}

¹ Estudiante de Doctorado en Sistemas de Ingeniería, Facultad de Ciencias Físicas y Matemáticas, Universidad de Chile.

Propuesta para Seminario de Investigación II 2020

RESUMEN

La presente propuesta de investigación aborda el desafío de elaborar un marco teórico referencial que permita comparar las legislaciones sobre la Política de Gobierno de Datos. Para esto, se presenta un escenario con bancos comerciales e instituciones tecnológicas FinTech que entregan servicios de “Shadow Banking”. Las empresas FinTech han contribuido en mejorar los sistemas financieros, ampliando la inclusión crediticia y con menores costos de administración; lo que se ha traducido en menores comisiones. Sin embargo, se ha reportado que algunas empresas han sido capaces de detectar sesgos conductuales y aprovechar estos sesgos en perjuicio de los consumidores. En este trabajo se propone comparar el bienestar de los consumidores bajo (1) gobierno centralizado de datos; (2) mercado competitivo del crédito (sólo se conoce historial de transacciones desde que un cliente se afilie a una institución); (3) clientes se trasladan con sus datos históricos[†].

Palabras Clave: *FinTech*, *Shadow Banking*, Equilibrio General, Teoría de Juegos, *Credit Scoring*.

1 INTRODUCCIÓN

En los últimos años ha existido una gran discusión respecto a la incorporación de empresas tecnológicas al rubro del mercado de crédito. Esta discusión se ha intensificado ante la crisis mundial socio-económica generada por la pandemia del coronavirus COVID-19. Estas empresas denominadas “Fintech” han colaborado con una mayor inclusión digital crediticia (clientes que no estaban afiliados a bancos comerciales), menores tiempos en el proceso de aprobación y otorgamiento de micro-créditos, e incluso han colaborado con los gobiernos para entregar transferencias monetarias, entre otras políticas públicas (1). Sin embargo, no han estado exentas de críticas.

Estudios demuestran que las empresas FinTech, en conjunto con las empresas tecnológicas denominadas “BigTech”, poseen fuentes de información “alternativas”, a las que no pueden acceder los bancos, que les permite obtener mejores pronósticos sobre la probabilidad de “default” de los consumidores. Tobias Berg, Valentin Burg, Ana Gombović y Manju Puri (2) demuestran que modelos alimentados con información del correo electrónico junto con información de los “smartphones” de los clientes, logran mejores pronósticos en relación a la probabilidad de “default” que el “Credit Bureau Score” usado por los bancos comerciales. Esto es beneficioso para resolver el problema de selección adversa, sin embargo, si la menor probabilidad de pago está asociada a una menor educación financiera puede ser utilizada malintencionadamente.

Algunas empresas manipulan la complejidad de las fuentes de información y términos de contrato para clientes con menor edu-

cación financiera. Antoinette Schoar y Hong Ru (3) usando la información de las cartolas de facturación de compañías que otorgan tarjetas de créditos, encuentran evidencia de “screening[‡]” por parte de las instituciones basado en sesgos conductuales y nivel educacional; en donde se entrega información de las tasas y comisiones de manera más compleja o en un formato menos visible o menos atractivo[§] para clientes con menor educación financiera. Adicionalmente, encuentran que el fenómeno de “shroading[¶]” de las compañías crediticias es menor cuando los individuos menos sofisticados no pueden pagar (mayor tasa de desempleo del condado), ya que si entregan la información de tal forma que los clientes menos sofisticados aceptan contratos menos justos, los clientes podrían caer en “default”.

La incorporación de empresas FinTech y una menor restricción a sus políticas de uso de datos exponen un claro “trade-off”. Por un lado, estas empresas poseen un mayor poder predictivo para determinar las probabilidades de “default” que permitirían reducir el problema de selección adversa, pero por otra parte, esta tecnología podría inducir una suerte de “discriminación de precios basada en ingenuidad^{||}”. Más aún, si el gobierno posee mayor preocupación por aquellos individuos con sesgos conductuales, estaría interesado en perpetuar el problema de selección adversa, ya que individuos con mayor educación financiera subsidiarían una tasa de interés menor para individuos más riesgosos.

[‡] Filtro de acuerdo a características de los clientes.

[§] Tamaño de fuente pequeño o al reverso de la cartola

[¶] Entregar información en un formato más complejo para individuos con menor formación financiera.

^{||} También denominado *naïveté price based discrimination*.

* Universidad de Chile, FCFM

A quién le corresponde la propiedad de los datos no es claro. No obstante, independiente si le pertenecen al cliente o a la empresa, los datos son un activo importante para las corporaciones. De acuerdo a un reporte del año 2011 de la consultora McKinsey (4) los datos masivos son clave para la competencia, productividad, innovación y bienestar de los consumidores. La información que sirva para predecir con mayor nivel de certeza el comportamiento de individuos como probabilidad de pago de créditos, desarrollo de patologías o adherencia política podría ser muy valiosa.

Recientemente, han ocurrido casos emblemáticos por venta ilegal de datos como Cambridge Analytica (5) en donde las empresas ofrecieron servicios por millones de dólares entorno al uso de datos privados de usuarios. El “*Technology Policy Institute*” (6) estimó el valor de la información que le otorga cada usuario a la plataforma “*Facebook*” podría ser superior a \$8 USD mensuales. Y aún no se ha explorado el valor de esta información en el sector financiero.

En miras de explorar normas de Gobierno de Datos, es relevante evaluar el bienestar de los consumidores frente a distintas políticas de datos. Sin embargo, no hay un desarrollo maduro de Gobierno de Datos. Es por esto, que mientras no hayan datos que permitan comparar políticas (en un entorno causal), en un período de tiempo razonable, para evaluar estas políticas es necesario hacer estudios locales o análisis teóricos (por ejemplo: modelos de Equilibrio General y simulaciones).

Para este trabajo se analizarán tres políticas de Gobierno de Datos en el contexto de información de historial financiero; la primera es la creación de un organismo gubernamental de datos, en donde los datos son públicos pero anonimizados; la segunda es una política en la que “el consumidor es dueño de sus datos” y migra con ellos al cambiarse de compañía; la tercera es una política en la que “la empresa es dueña de los datos” y tiene su propiedad independiente si el cliente se afilia a otra empresa.

En el contexto de un mercado de crédito cuyos únicos oferentes son los bancos tradicionales, que tienen muchos datos históricos y que comparten la misma tecnología para predecir probabilidad de “*default*”, las consecuencias son previsibles. Ya que si diferenciamos a “buenos pagadores” y “malos pagadores” por la varianza de la probabilidad de pago de un crédito; y si los bancos no pueden estimar esta “varianza poblacional” para cada grupo, el resultado será una tasa de interés homogénea para todos los individuos, bajo las tres políticas de Gobierno de Datos. Sin embargo, al incluir a las FinTech que poseen mayor información pero mayor probabilidad de usar malintencionadamente los datos surge un “*trade-off*”.

El “*trade-off*” ocurre al permitir que las empresas FinTech compitan en el mercado de micro-créditos con los bancos tradicionales; por un lado, su mejor capacidad de predicción de “*default*” permite resolver el problema de selección adversa, eliminando un subsidio de tasas cruzado desde los individuos más educados financieramente a los menos educados, lo que beneficia a los consumidores menos riesgosos pero promueve una mayor desigualdad financiera. Además, la incorporación de empresas FinTech integra un riesgo adicional de “uso malintencionado” de los sesgos de los consumidores. Este riesgo de mal uso de los datos es aún mayor cuando se toma en cuenta la menor formación informática que poseen los reguladores locales (1), respecto a las FinTech, en ocasiones internacionales, que podría implicar períodos de tiempo prolongados antes de detectar estos artificios.

Este estudio plantea dos desafíos importantes; en primer lugar, estos “*trade-off*” son un fenómeno reciente, poco estudiado, por lo que no existen datos reales que permitan realizar un análisis

causal del bienestar de los individuos o literatura robusta, guía, para comparar las tres políticas de Gobierno de Datos propuestas; el segundo desafío es que al ser un modelo teórico debe poseer supuestos necesarios para comparar los “*trade-off*” y que las conclusiones obtenidas sean coherentes con la realidad. Por último, el modelo que plantearemos no es un modelo “cerrado” debido a la naturaleza algorítmica de la modelación de los agentes (para representar de mejor forma la realidad), es por esto, que deberá ser analizado con métodos numéricos** que ocasionalmente son muy inestables y pueden diverger, entregando conclusiones poco coherentes.

2 ¿A QUIÉN LE PERTENECEN LOS DATOS?

De acuerdo a la organización “*Statista*”, sólo el año 2018 se generó un flujo de 10.6 zettabytes desde las plataformas de “*cloud storage*” o almacenamiento de nube (7). Es decir, existió un flujo de 1.06 billones de terabytes de información que almacenan las compañías, que en su mayoría deben provenir de sus clientes. Pero ¿a quién le pertenecen estos datos?

De acuerdo al Teorema de Coase (8) los derechos de propiedad se reasignan hacia a aquellos que más lo valoran††. Sin embargo, el debate sobre a quién le pertenecen los datos no está sanjado y la legislación sobre estos temas se remite a legislaciones locales que dependen de la naturaleza de los datos.

Muchos artículos han estudiado los aspectos filosóficos y prácticos del uso de fuentes masivas de información, pero en general, el foco es en el tipo de variables que se utilizan para construir los modelos, en lugar analizar los derechos de propiedad de los datos; para evitar problemas como discriminación o brechas de género.

Con el surgimiento de empresas que ofrecen servicios de “nubes de almacenamiento” se complejiza aún más el problema. Supongamos que una empresa de seguridad ofrece cámaras de seguridad que pueden ser revisadas en tiempo real por los clientes de manera remota. Si estos datos son grabados y almacenados en una nube, no es claro a quién le pertenecen las grabaciones. ¿Es correcto que la empresa de seguridad utilice las grabaciones para entrenar algoritmos que identifiquen y reporten automatizadamente la existencia de amenazas? ¿la compañía de almacenamiento puede utilizar los datos del video para mejorar sus servicios? si el cliente deja de pagar la suscripción de la empresa de seguridad ¿deben ser eliminados o pueden almacenarse por si el cliente vuelve a suscribirse?

Existe un consenso en las ciencias del principio de “*openness*” (9), en el que se reconoce que la sociedad se beneficia de la accesibilidad a los datos, y sobre todo de la integridad de datos que puedan ser usados por científicos. En relación a datos “de uso científico” (10) expone que compartir los datos refuerza la labor científica, promoviendo una mayor diversidad de perspectivas y conclusiones. Sin embargo, cuando los datos podrían ser utilizados por ciertos agentes de la sociedad en desmedro de otros, no es tan evidente el beneficio de compartirlos.

Este problema ha sido ampliamente estudiado en el aspecto de “datos de salud”. En primera instancia, no es claro si los datos le pertenecen al paciente, al médico, a la institución, o a la plataforma de “*Historial Médico*” (“*Electronic Health Record*”) utilizada por

** Reinforcement Learning.

†† Siempre y los costos de transacción no sean muy elevados.

varias instituciones. Este dilema es particularmente importante si una aseguradora de salud planea comprar estos datos para resolver el problema de selección adversa de sus asegurados ¿puede comprarlos a alguien que no sea el paciente? En 1996 se promulgó en Estados Unidos el acta HIPAA (“*Health Insurance Portability and Accountability Act*”) que protege a los pacientes, e impide la difusión de sus datos sin consentimiento.

En relación a la protección de datos bancarios, también se promulgó un acta. En 1999, el Congreso estadounidense promulgó el acta “*Gramm-Leach-Bliley*” que imponía una serie de restricciones al actuar de instituciones financieras, que incluían restricciones a fusiones y al uso o venta de los datos de los clientes. Sin embargo, esta acta no prohíbe la existencia de las denominadas “oficinas de crédito” (“*Credit Bureau*”) que son agencias que reúnen la información de hábitos de pago de múltiples fuentes prestamistas. Estas empresas existen en varios países, entre ellos, Estados Unidos, Australia, India, Reino Unido y Filipinas. Esta información puede ser utilizada por compañías que ofrecen préstamos sin el consentimiento de los clientes. La existencia de estas instituciones se justifica en otorgar una mayor estabilidad al sistema financiero de un país, además de mejorar la calidad en los portafolios de crédito, lo cual ha sido corroborado por (11), (12) y (13).

En la sección siguiente se expone un modelo que permita comparar tres políticas de Gobernanza de Datos en la industria de créditos. En la primera, se asume que los datos son públicos, y los administra el gobierno (análogo a la existencia de “*Credit Bureau*”). En la segunda, se asume que los datos históricos le pertenecen al cliente, por lo que el cliente puede migrar con sus datos a otra empresa. En la tercera, se asume que los datos históricos le pertenecen a las empresas (análogo a Chile), y si un cliente se afilia a una nueva institución, esta no tendrá información respecto a su pasado.

3 METODOLOGÍA

El modelo propuesto es un modelo de Equilibrio General del mercado de crédito, en donde las empresas FinTech compiten con los bancos tradicionales. El modelo permite endógenamente la posibilidad de “pagar a los consumidores por sus datos” a una menor tasa de interés que la “prima justa” predicha para ese consumidor. Además incorpora la existencia del subsidio cruzado que existe en el sistema bancario, la potencial solución a este problema de selección adversa, y la posibilidad de “*shrouding*” de parte de las FinTech. El supuesto clave es que existen individuos “poco educados financieramente” que poseen una amplia dispersión de probabilidad de no pagar créditos y que están más expuestos a ser engañados. Finalmente se incorpora al Estado como un organismo “regulador” que fiscaliza a cierta proporción de empresas FinTech en cada período.

Con el modelo propuesto se analizarán cuatro variables; (1) endeudamiento de los individuos (para alto y bajo riesgo); (2) elecciones de los individuos en el largo plazo (si se converge a un estado estacionario, reportar cuántos individuos optaron por migrar a empresas FinTech); (3) fenómeno de “*shrouding*” ante distintos regímenes de gobierno de datos; (4) bienestar neto de los consumidores (y su dinámica).

3.1 Fundamentos del Modelo

- Los individuos consumen de acuerdo a una heurística keynesiana. Es decir, poseen un “consumo autónomo” (consumo mínimo

para sobrevivir) y una “propensión marginal a consumir”. Esta regla puede modificarse por la ecuación de Euler, e incorporar endógenamente ahorro por precaución. Sin embargo, en este trabajo estamos interesados en ver las políticas óptimas de empresas FinTech y gobierno. Es por esto, que simplificamos el consumo a una regla fija.

- Existen dos tipos de consumidores; consumidores “de alto riesgo” y consumidores de “bajo riesgo”. La probabilidad de pagar inherente a cada individuo (y por ende constante en todos los períodos) es una variable aleatoria que se obtiene a partir de dos distribuciones diferentes de acuerdo al tipo de individuo. Ambas distribuciones poseen la misma media pero diferente varianza. Este supuesto representa la existencia de individuos “con educación financiera” cuya dispersión de probabilidad de default es menor a la de individuos poco educados.

- Las empresas FinTech pueden discriminar entre clientes de tipo “más y menos riesgosos” pero los bancos no. Este supuesto es consistente con que los bancos poseen modelos predictivos más simples y no tienen acceso a otras variables conductuales que sí poseen las FinTech.

- Las empresas FinTech observan la probabilidad real de “*default*” de cada individuo más un sesgo. Cada vez que las FinTech tiene más datos de clientes-mes disminuye la varianza de este sesgo (cuya media es cero). A través de esta forma se incorpora endógenamente el “valor de la información” marginal que entrega cada cliente. Es por esto, que la empresa FinTech estaría dispuesta a ofrecer tasas de interés más bajas en el presente para obtener mayor información para el futuro. Este descuento en la tasa de interés será mayor bajo el Gobierno de Datos “los consumidores son dueños de sus datos”.

- Los bancos poseen mayores costos operacionales por lo que se normaliza a cero el costo de operación de las empresas FinTech.

- Existe un solo banco y “N” empresas FinTech.

- Asumimos que sólo los individuos más riesgosos pueden ser engañados por las FinTech. Para incorporar esto al modelo podemos asumir que existe un “costo de mirar otras tasas de interés”. Esto es creíble, ya que sería asumir que existe un sesgo hacia el “*status quo*”, expresado en términos de un “costo intelectual” para buscar otras tasas más bajas. De esta forma, se permite la existencia de “*shrouding*”, e individuos con un mayor costo de “búsqueda” estarán más expuestos a este engaño.

- El gobierno puede fiscalizar a un número limitado de empresas FinTech en cada período.

- Cuando el gobierno fiscaliza y detecta “*shrouding*” en una empresa FinTech, la penaliza con una multa “M” por cada cliente “engañado”.

- Bajo la política de Gobierno de Datos públicos anonimizados, suponemos que no existe la posibilidad de “engaño” de las FinTech, ya que el gobierno posee acceso a los datos sobre las tasas ofrecidas.

- Cuando el individuo está indiferente entre pedir el préstamo al Banco o a alguna(s) Fintech, lo pedirá en la empresa donde pidió su último préstamo, o en caso que no haya pedido, aleatoriamente entre las firmas en cuestión.

3.2 Modelo

En esta sección se presenta un “*Set-up*” tentativo e incompleto del modelo final. Pretende ser una guía del modelo final, y un paso intermedio para corroborar las consecuencias de los supuestos.

3.2.1 *Consumidores*

La utilidad de los consumidores en cada período está definida como consumo de un modelo keynesiano. En donde el ingreso disponible depende de los ahorros (a_t), deuda (d_t), tasa de colocación (r_t) y del ingreso estocástico (Y_t), y en caso de que el ingreso sea inferior al consumo autónomo el individuo pide un crédito al banco o empresa FinTech (j), a una tasa r_{jt} . Por lo que, si pide prestado un crédito deberá pagar, en el siguiente periodo, el monto adeudado d_{t-1} multiplicado por uno más la tasa de interés r_{jt} .

$$u_t^i \equiv c_0 + c_1 \cdot \left(Y_t^i + a_{t-1} - d_{t-1}^i \cdot (1 + r_{jt}) \right)$$

$$\gamma_t \equiv Y_t^i - d_{t-1}^i \cdot (1 + r_{jt})$$

$$a_t \equiv \begin{cases} \gamma_{t-1} & , \text{ si } \gamma_{t-1} \geq 0 \\ 0 & , \text{ si } \gamma_{t-1} < 0 \end{cases}$$

$$d_t \equiv \begin{cases} \gamma_{t-1} & , \text{ si } \gamma_{t-1} \leq 0 \\ 0 & , \text{ si } \gamma_{t-1} > 0 \end{cases}$$

Los consumidores pueden pertenecer al tipo de alto riesgo (H) o al de bajo riesgo (L). Podemos notar que bajo esta configuración, la probabilidad de no pago es endógena, y la baja educación financiera está modelada por Y_t . Esto podría representarse de otras maneras, como una variable aleatoria binaria que represente el pago^{††}.

La elección de afiliación en cada período depende de la oferta de tasas de interés que le hagan las empresas (banco y empresas FinTech).

$$r_{jt} \equiv \arg \min_{j \in \{Banco \cup Fintech\}} \{r_{jt}\}$$

Los individuos de tipo “más riesgoso” (menos educados financieramente) deben pagar un costo ω para ver las tasas que ofrecen las demás compañías. Por ende, las utilidades en cada período son las siguientes para los respectivos tipos.

$$u_t^L \equiv c_0 + c_1 \cdot \left(Y_t^L + a_{t-1} - d_{t-1}^L \cdot (1 + r_{jt}) \right)$$

$$u_t^H \equiv c_0 + c_1 \cdot \left(Y_t^H + a_{t-1} - d_{t-1}^H \cdot (1 + r_{jt}) - \omega_h x \right)$$

Con x una variable auxiliar que representa la decisión de buscar tasas más bajas.

3.2.2 *Gobierno*

La utilidad del gobierno en cada período es la suma de las utilidades de los consumidores pero con diferentes ponderadores:

$$U_t^G \equiv \sum_{h \in H} u_t^h(r_t^h) + \alpha \sum_{l \in L} u_t^l(r_t^l)$$

3.2.3 *Bancos*

Los bancos ofrecen una tasa de interés igual a la probabilidad de no pago esperada de sus clientes activos, que asumimos que ya la conocen, un factor más costos de administración.

$$r_{jt} \equiv \mathbb{E} \{ \mathbb{P}(\text{pago}) \} + \frac{\varphi}{\#Clientes_t}$$

^{††} En ese caso el individuo optaría por no pagar el crédito pero aún se permitiría que ahorre o consuma todo sus ingresos.

3.2.4 *FinTech*

Las FinTech pueden diferenciar entre individuos de distintas poblaciones, sin embargo, observa la probabilidad esperada con cierto error (que decae con la cantidad de datos históricos que va acumulando). Una forma de modelar esto es la siguiente:

$$\hat{\mathbb{P}}_{jit}(\text{default}_{it}) = \mathbb{P}_{it}(\text{default}_{it}) + e^{-T} \cdot \text{Sesgo}$$

En donde $\mathbb{P}_{it}(\text{default}_{it})$ denota la probabilidad de que el individuo i no pague un crédito en el período t , y $\hat{\mathbb{P}}_{jit}(\text{default}_{it})$ denota el estimador de esta probabilidad que observa la empresa j . T es la cantidad de datos cliente-mes que posee la empresa. Cabe destacar que la probabilidad de “default” es algo inherente a cada individuo, y viene dado por la siguiente probabilidad:

$$\mathbb{P}_{it}(\text{default}_{it}) = \mathbb{P}_{it} \left(Y_t^i + a_{t-1} < d_{t-1}^i \cdot (1 + r_{jt}) \right)$$

Por ende, la utilidad esperada en cada período (t) que una empresa FinTech (j) obtiene por cada cliente (i) sería algo de la siguiente forma:

$$\pi_{jit} = \left[(1 + r_{t-1}^i) \cdot d_{t-1}^i \right] \cdot \mathbb{P}_{it}(\text{default}_{it}) - d_{t-1}^i + \left[\psi d_{t-1}^i \cdot (1 - \Lambda) - M \cdot \Lambda \right] \cdot y_{i,t-1}$$

En donde ψ es el valor monetario del “shroading” expresado como tasa de interés adicional sobre lo que se le cobra al cliente i ^{§§}. Λ es la probabilidad de ser fiscalizado (suponemos constante en todos los períodos), M es la multa que aplica el gobierno si detecta el engaño por cada cliente engañado; $y_{i,t-1}$ es una variable auxiliar binaria que toma el valor 1 si la empresa decide hacer “shroading” al cliente i .

El primer término $\left[(1 + r_{t-1}^i) \cdot d_{t-1}^i \right] \cdot \mathbb{P}_{it}(\text{default}_{it})$ representa el valor esperado de haber prestado d_{t-1}^i en el período $t - 1$.

El segundo término $-d_{t-1}^i$ es el préstamo d_{t-1}^i realizado al cliente i en el período t (que podría ser 0).

El tercer término $\left[\psi d_{t-1}^i \cdot (1 - \Lambda) - M \cdot \Lambda \right]$ representa el valor esperado de la ganancia neta por haber engañado a un cliente en el período anterior ($t - 1$).

Cabe destacar que la gran complejidad de resolver esta maximización es que la empresa no conoce $\mathbb{P}_{it}(\text{default}_{it})$ que pondera a d_{t-1}^i . Si el término d_{t-1}^i no estuviese en otra parte de la utilidad, no importaría que la probabilidad fuese desconocida, ya que, el valor óptimo de d_{t-1}^i no dependería de la probabilidad de la que es ponderado (asumiendo que la probabilidad de no pago es mayor a cero).

3.3 *Resolución del Problema*

Debido a la naturaleza “algorítmica” de las acciones de las empresas Fintech, no existirá una política óptima de forma cerrada para el problema. Por lo que será necesario utilizar metodologías de análisis numérico, como por ejemplo Aprendizaje Reforzado (14). La principal desventaja que presentan estas metodologías, además de requerir que los supuestos sean consistentes con la realidad, es que los resultados óptimos podrían ser poco estacionarios (y diverger a conclusiones poco realistas).

^{§§} Sólo si el cliente es de tipo “riesgoso”.

3.4 Nota adicionales para resolver el problema

Podemos notar que bajo este “*set up*”, el riesgo de no pago de los clientes sólo es incorporado en la distribución poblacional del ingreso (Y^i). Sin embargo, podría estar relacionada a la propensión marginal a consumir (c_1) u otras variables relativas a sesgos conductuales de los individuos (p.j. coeficiente de consumidores miopes en una función de descuento hiperbólico y consumo determinado de acuerdo a la Ecuación de Euler).

Una forma de resolver el problema de forma alternativa es replantear el problema de optimización con restricciones adicionales, incluyendo condiciones para el “*market clearing*”, y se podría resolver el problema con metodologías de optimización con incertidumbre.

4 RESULTADOS ESPERADOS

En el escenario de “datos históricos públicos anonimizados” existirá una migración espontánea de la mayoría de los individuos hacia el sector FinTech, quienes poseen datos suficientes para predecir con un bajo error la probabilidad de pago de sus clientes. Ya que, al poseer menos costos de administración ofrecerán tasas inferiores a las del banco. Sin embargo, durante el primer período los individuos de menor probabilidad de pago tendrán un pequeño lapso de tiempo con tasas de interés más bajas que la ofrecida por las FinTech, debido a la incapacidad de los bancos de resolver el problema de selección adversa. Sin embargo, a medida que los individuos de menor riesgo de “*default*” migren al sistema FinTech se reducirá este subsidio cruzado, hasta que finalmente aumentará la tasa del banco hasta el punto en que superarán la tasa de las FinTech y exista una migración absoluta de los clientes al sector FinTech.

Bajo cualquiera de las otras dos políticas, probablemente en primera instancia exista una migración de individuos de cualquier tipo hasta que las empresas FinTech tengan información suficiente para predecir con bajo sesgo la probabilidad de “*default*” de los clientes. Después de muchos períodos existirá una gran migración de individuos de bajo riesgo al sector FinTech, y dependiendo de los parámetros (como la magnitud de la multa por “*shrouding*”) existirán empresas FinTech que óptimamente “engañarán” a los clientes del tipo “más riesgoso” (menos educados financieramente). La velocidad con que ocurra esta migración probablemente sea inferior bajo la política de Gobierno de Datos “datos propiedad de las empresas” que en la de “datos propiedad de los consumidores”. Sin embargo, los resultados agregados, netos, de nivel de endeudamiento y bienestar de los consumidores no es evidente; ya que, en el escenario en que la migración de individuos menos riesgosos al sector FinTech es más rápida, el valor de la información que otorga cada cliente es mayor, y la migración en primera instancia podría beneficiar equitativamente a los individuos de mayor y menor riesgo. Por ende, algunos clientes de tipo “riesgosos” (y pioneros en cambiarse de sistema) podrían beneficiarse más que bajo el régimen “datos propiedad de las empresas” en donde se disuelve más rápidamente el subsidio cruzado de tasas.

Después de la migración de individuos menos riesgosos hacia el sector FinTech, los bancos deberían subir las tasas a los clientes que no migren; en primer lugar por un aumento en el costo medio de operación (menos clientes); y en segundo lugar, por un fenómeno similar al “mercado de los limones” (15), ya que, debido a que el banco sabe que la gente de menor riesgo es identificada por las FinTech, y sólo se quedarán individuos de mayor riesgo en el banco, y por ende, les cobrará un mayor premio por riesgo. Es

por esto, que si el gobierno posee mayor preferencia por individuos de alto riesgo, elegirá la política de Gobierno de Datos que imponga barreras a las empresas FinTech, que probablemente será la de “los datos le pertenecen a las empresas”. Sin embargo, después de varios períodos, si las empresas FinTech no incurrir en el fenómeno de “*shrouding*” o no son fiscalizadas por el gobierno, eventualmente ocurrirá la migración de clientes de bajo riesgo al sector FinTech.

REFERENCIAS

- R. Sahay, U. E. von Allmen, A. Lahreche, P. Khera, S. Ogawa, M. Bazarbash, K. Beaton, *et al.*, “The promise of fintech; financial inclusion in the post covid-19 era,” tech. rep., International Monetary Fund, 2020.
- T. Berg, V. Burg, A. Gombović, and M. Puri, “On the rise of fintechs: Credit scoring using digital footprints,” *The Review of Financial Studies*, vol. 33, no. 7, pp. 2845–2897, 2020.
- R. Hong and A. Schoar, *Do Credit Card Companies Screen for Behavioral Biases?* National Bureau of Economic Research, 2016.
- McKinsey.com, “Big data: The next frontier for innovation, competition, and productivity.”
- Nytimes.com, “Facebook’s data deals are under criminal investigation.”
- J. Prince and S. Wallsten, “How much is privacy worth around the world and across platforms?,” *Available at SSRN*, 2020.
- Statista.com, “Big data - statistics & facts.”
- R. H. Coase, “The problem of social cost,” in *Classic papers in natural resource economics*, pp. 87–137, Springer, 1960.
- N. A. of Sciences, N. A. of Engineering, and I. of Medicine, *Responsible Science: Ensuring the Integrity of the Research Process: Volume II*. Washington, DC: The National Academies Press, 1993.
- S. E. Fienberg, M. E. Martin, and M. L. Straf, *Sharing research data*. National Academy Press, 1985.
- V. Simovic, V. Vaskovic, and D. Poznanovic, “A model of credit bureau in serbia-instrument for preserving stability of the banking sector in conditions of the global economic crisis.,” *Journal of applied quantitative methods*, vol. 4, no. 4, 2009.
- R. B. Avery, P. S. Calem, and G. B. Canner, “Credit report accuracy and access to credit,” *Fed. Res. Bull.*, vol. 90, p. 297, 2004.
- M. Miller, “Reporting systems and the international economy,” 2003.
- A. Charpentier, R. Elie, and C. Remlinger, “Reinforcement learning in economics and finance,” *arXiv preprint arXiv:2003.10014*, 2020.
- G. A. Akerlof, “The market for “lemons”: Quality uncertainty and the market mechanism,” in *Uncertainty in economics*, pp. 235–251, Elsevier, 1978.